

Clasificación de Señales Eco-Acústicas para la Identificación Autónoma de Especies Faunísticas

Equipo X · CS3061 Machine Learning · UTEC

1 de julio de 2026

1. Resumen Ejecutivo e Introducción al Espacio Vectorial

1.1. Definición del problema

El monitoreo bioacústico pasivo constituye una herramienta clave para la conservación de la biodiversidad, al permitir estimar la presencia de especies en un hábitat sin intervención humana directa. En el presente trabajo se aborda la identificación automática de especies faunísticas a partir de registros eco-acústicos pre-procesados. Formalmente, se dispone de un conjunto de N observaciones, donde cada muestra se representa mediante un vector de características $\mathbf{x} \in \mathbb{R}^{64}$ compuesto por los coeficientes condensados de la escala Mel (MFCC), $\{\text{mel}_0, \dots, \text{mel}_{63}\}$. Dichos coeficientes capturan las propiedades de frecuencia y timbre de la señal de audio digital.

El problema se formula como una tarea de **clasificación supervisada multiclase** sobre la variable objetivo **species_id**, acotada a cinco clases ($\{10, 12, 17, 18, 23\}$) correspondientes a dos anfibios y tres aves (Cuadro 1). Las variables **recording_id**, **songtype_id** e **is_tp** constituyen metadatos y fueron excluidas del espacio de predictoras. Cabe destacar que la distribución de clases es **asimétrica**, con una razón de desbalance aproximada de 2:1 entre la clase mayoritaria (23, con 553 muestras) y la minoritaria (10, con 277) (Figura 1), condición que determina la elección del **F1-Score macro** como métrica rectora de la evaluación.

Cuadro 1: Catálogo taxonómico de las clases objetivo del dataset.

species_id	Nombre científico	Tipo de fauna
10	<i>Leptodactylus discodactylus</i>	Anfibio
12	<i>Osteocephalus taurinus</i>	Anfibio
17	<i>Chiroxiphia lineata</i>	Ave
18	<i>Saltator grossus</i>	Ave
23	<i>Pheucticus chrysopheplus</i>	Ave



Figura 1: Distribución de clases en el conjunto de entrenamiento. Se evidencia el desbalance entre especies, dominado por las clases 17 y 23.

1.2. Arquitectura del pipeline

La solución propuesta se estructura como un pipeline integral que abarca desde la ingesta de los archivos CSV hasta la inferencia con mitigación de riesgos. La Figura 2 ilustra el flujo completo: ingesta y separación de predictoras/metadatos, estandarización, exploración geométrica mediante reducción de dimensionalidad, minería de patrones por clustering, entrenamiento comparativo de clasificadores y, finalmente, la política de moderación basada en umbrales probabilísticos.




Figura 2: Arquitectura del pipeline propuesto, desde la matriz base de características Mel hasta el despliegue informativo.

2. Exploración Geométrica y Reducción de Dimensionalidad

Con el objetivo de visualizar la estructura geométrica del espacio $\mathbb{R}^{64}$ y evaluar la separabilidad de las clases, se contrastaron un método lineal y dos métodos de aproximación de variedades múltiples.

2.1. Análisis comparativo

El **Análisis de Componentes Principales (PCA)** proyecta los datos sobre los ejes ortogonales de máxima varianza, preservando la **estructura global** de forma lineal. Se determinó que se requieren 7 componentes para retener el 90 % de la varianza y 11 para el 95 % (Figura 3); las dos primeras componentes retienen únicamente el 67,1 % de la varianza total, lo que anticipa un solapamiento al proyectar a 2D.

En contraste, **t-SNE** y **UMAP** son técnicas no lineales que preservan las **distancias geométricas locales**, priorizando que las vecindades del espacio original se mantengan en la proyección de baja dimensión. La Figura 4 contrasta las tres proyecciones en 2D y la Figura 5 muestra la proyección UMAP en 3D.




Figura 3: Varianza explicada acumulada en función del número de componentes principales. Las líneas punteadas indican los umbrales del 90 % y 95 %.




Figura 4: Proyecciones 2D del espacio Mel coloreadas por especie: PCA (lineal) frente a t-SNE y UMAP (variedades). Las técnicas no lineales separan mejor los grupos que la proyección lineal.

Figura 3b. Proyeccion UMAP 3D por especie




Figura 5: Proyección UMAP en 3 dimensiones del conjunto de entrenamiento.

2.2. Justificación técnica

El Cuadro 2 reporta el compromiso entre costo computacional y retención de estructura. PCA resultó el método más eficiente (0,01 s) por su naturaleza algebraica, pero su *trustworthiness* fue la menor, coherente con su incapacidad de capturar relaciones no lineales. t-SNE y UMAP incrementaron el tiempo de cómputo a 11,9 s y 11,3 s respectivamente, a cambio de una mayor preservación de la estructura local (*trustworthiness* de 0,987 y 0,977, frente a 0,867 de PCA). En consecuencia, las técnicas de variedades resultan preferibles para la **visualización** y la inspección de separabilidad, mientras que PCA se reserva como paso de **compresión** previo al clustering por su bajo costo y su interpretabilidad en términos de varianza.

Cuadro 2: Comparativa de métodos de reducción de dimensionalidad: tiempo de ejecución y retención de estructura local (*trustworthiness*, $k = 10$).

Método	Tiempo (s)	<i>Trustworthiness</i>	Tipo
PCA	0,01	0,867	Lineal (varianza global)
t-SNE	11,91	0,987	Variedad (estructura local)
UMAP	11,26	0,977	Variedad (estructura local)

3. Minería de Patrones y Estructuras de Clustering


Se evaluaron dos algoritmos de aprendizaje no supervisado basados en paradigmas distintos. Dado que, según la Sección 2 (Figura 3), 11 componentes principales son suficientes para retener el 95 % de la varianza, el clustering se aplicó sobre dicho subespacio en lugar del espacio original $\mathbb{R}^{64}$. Esta compresión previa reduce el ruido y el costo computacional sin sacrificar información relevante, y mitiga el efecto de la *maldición de la dimensionalidad* sobre las métricas basadas en distancias.

3.1. Segmentación orgánica


El **Gaussian Mixture Model (GMM)** adopta un paradigma **probabilístico**: modela los datos como una mezcla de k distribuciones gaussianas y asigna a cada punto una probabilidad de pertenencia (*soft assignment*). El **DBSCAN** adopta un paradigma de **densidad**: agrupa regiones densas y etiqueta como ruido los puntos aislados, sin requerir la especificación previa del número de grupos, pero con fuerte dependencia del hiperparámetro ε . El valor de ε se estimó mediante el gráfico de k -distancia (Figura 6b), identificando el codo de la curva, y se realizó un barrido fino alrededor de dicho valor.

3.2. Métricas de validación

La elección del número óptimo de grupos se sustentó exclusivamente en **métricas internas** (que no emplean las etiquetas reales): el **Coefficiente de Silhouette**, el índice de **Davies-Bouldin** y el de **Calinski-Harabasz** (Figura 7). El criterio de Silhouette sugirió $k = 2$ grupos para GMM ($s = 0,184$), valor corroborado por las restantes métricas internas (mínimo de Davies-Bouldin y máximo de Calinski-Harabasz en $k = 2$) y por el criterio BIC (Figura 6a). El Cuadro 3 sintetiza el desempeño; adicionalmente, el índice de Rand ajustado (ARI), calculado de forma externa, cuantifica el grado de alineación entre los grupos descubiertos y la taxonomía real.



(a) GMM: Silhouette y BIC frente a k .



(b) DBSCAN: gráfico de k -distancia.

Figura 6: Selección de hiperparámetros para los dos algoritmos de clustering.




Figura 7: Validación interna cruzada del número de grupos en GMM mediante Silhouette, Davies-Bouldin y Calinski-Harabasz.

Cuadro 3: Comparativa de los algoritmos de clustering. ARI se reporta como referencia externa de alineación con `species_id`.

Método	Paradigma	Grupos	Silhouette	ARI
GMM	Probabilístico	2	0,184	0,026
DBSCAN	Densidad	2	–	0,004

Los valores de Silhouette próximos a cero y los índices ARI cercanos a 0 (0,026 para GMM y 0,004 para DBSCAN) constituyen un hallazgo relevante: la estructura no supervisada del espacio Mel **no se organiza en cinco grupos densos separables** que coincidan con la taxonomía. Ambos algoritmos favorecen $k = 2$, lo que sugiere una separación macroscópica (posiblemente señal robusta frente a registros ruidosos, o anfibios frente a aves) antes que la discriminación fina entre especies. Este solapamiento acústico anticipa la dificultad intrínseca de la tarea de clasificación supervisada abordada en la siguiente sección.

4. Arquitectura de Clasificación: MLP vs. Modelos de Ensamble

4.1. Diseño de la red neuronal

Se implementó un Perceptrón Multicapa (MLP) en PyTorch. Para la clasificación multiclase se empleó como función de pérdida la **entropía cruzada categórica ponderada**. Dada una observación con logits

de salida $\mathbf{z} = (z_1, \dots, z_C)$, la capa *softmax* produce la distribución de probabilidad

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^C e^{z_j}}, \quad k = 1, \dots, C, \quad (1)$$

y la pérdida total sobre N observaciones se define como

$$\mathcal{L} = - \sum_{i=1}^N w_{y_i} \log \hat{p}_{i, y_i}, \quad (2)$$

donde y_i es la clase verdadera de la muestra i y w_{y_i} es el peso asignado a dicha clase, calculado de forma inversamente proporcional a su frecuencia para **compensar el desbalance**. El Cuadro 4 detalla la topología de la red.

Cuadro 4: Topología de la red MLP (configuración recomendada Linear→BatchNorm→ReLU→Dropout).

Capa	Tipo	Neuronas	Activación
Entrada	–	64	–
Oculto 1	Linear+BN+Dropout	128	ReLU
Oculto 2	Linear+BN+Dropout	64	ReLU
Salida	Linear	5	Softmax

4.2. Estrategia de regularización

Se analizó empíricamente el impacto de la **posición relativa** de las capas de Dropout y Batch Normalization sobre la estabilidad de las curvas de aprendizaje. La Figura 8 contrasta el orden Linear→BatchNorm→ReLU→Dropout frente a Linear→Dropout→BatchNorm→ReLU. Se observó que la configuración Linear→BatchNorm→ReLU→Dropout produjo curvas de validación más estables y una menor brecha entre las pérdidas de entrenamiento y validación, razón por la cual fue adoptada en el modelo final. Situar la normalización antes del *dropout* permite que las estadísticas de cada *batch* se estimen sobre activaciones completas, evitando la inestabilidad que introduce normalizar sobre un subconjunto ya diezmado de neuronas. No obstante, en ambas configuraciones se observa que, a partir de la época ~ 20 , la pérdida de validación se estabiliza e incluso repunta ligeramente mientras la de entrenamiento continúa descendiendo: una señal de **sobreajuste leve** que la regularización acota pero no elimina. Este comportamiento justifica el uso de *dropout* y sugiere que la incorporación de *early stopping* en torno a dicha época constituiría una mejora directa para futuras iteraciones.

Figura 6. Curvas de aprendizaje segun posicion BN/Dropout




Figura 8: Curvas de aprendizaje (pérdida frente a épocas) según la posición relativa de las capas de Batch Normalization y Dropout.

4.3. Benchmarking computacional

El MLP se comparó contra **XGBoost**, un modelo de ensamble basado en *gradient boosting* de árboles de decisión. La evaluación se sostuvo sobre el **F1-Score macro** y el análisis de las **matrices de confusión**

(Figura 9), dada la inadecuación de la métrica *accuracy* ante el desbalance de clases. El MLP alcanzó un F1-macro de 0,453, mientras que XGBoost obtuvo 0,466, situando a ambos modelos sensiblemente por encima del azar teórico ($\approx 0,20$ para cinco clases) pero en un régimen de dificultad elevada, coherente con el solapamiento detectado en la fase no supervisada. El modelo de ensamble superó marginalmente a la red neuronal. Un análisis desagregado por clase (Cuadro 5) matiza esta lectura. El XGBoost concentra su acierto en las clases mayoritarias –recall de 0,66 en la clase 23 y 0,54 en la 17–, a costa de penalizar severamente a las minoritarias (recall de 0,34 en la clase 12). El MLP, gracias a la ponderación de la pérdida, distribuye el acierto de forma más equitativa entre clases (recall de 0,61 en la clase 10 y 0,55 en la 18), lo que explica que su F1-macro no se distancie del ensamble pese a su menor *accuracy* global. El error dominante no se limita a las tres aves: la mayor masa de confusión se produce entre las clases 23 (ave) y 10 (anfibio) en ambos modelos (44 casos $23 \rightarrow 10$ en el MLP y 29 casos $10 \rightarrow 23$ en XGBoost), lo que sugiere que el solapamiento en el espacio Mel trasciende la frontera taxonómica y refuerza la dificultad intrínseca anticipada por el análisis no supervisado.

Cuadro 5: Recall por clase en el conjunto de prueba. El MLP (con pérdida ponderada) reparte el acierto de forma más homogénea; XGBoost privilegia las clases mayoritarias.

Modelo	Clase 10	Clase 12	Clase 17	Clase 18	Clase 23
MLP	0,61	0,51	0,41	0,55	0,33
XGBoost	0,39	0,34	0,54	0,36	0,66

Figura 7. Matrices de confusión en TEST




Figura 9: Matrices de confusión en el conjunto de prueba para el MLP (izquierda) y XGBoost (derecha).

5. Decisiones de Ingeniería y Mitigación de Riesgos

5.1. Análisis de *trade-offs*

La selección del modelo de despliegue contempla el compromiso entre rendimiento analítico y costo computacional. El Cuadro 6 contrasta el F1-macro frente al tiempo de inferencia por registro. Si bien XGBoost ofrece el mejor F1-macro (0,466), su tiempo de inferencia de 0,830 ms por registro es aproximadamente 3,6 veces superior al del MLP (0,229 ms), lo que debe ponderarse frente al volumen de registros esperado en producción. Dada la diferencia marginal en rendimiento, el MLP constituye una alternativa competitiva cuando la latencia es crítica.

Cuadro 6: Compromiso entre rendimiento (F1-macro) y costo (tiempo de inferencia por registro).

Modelo	F1-macro	Inferencia (ms/registro)
MLP	0,453	0,229
XGBoost	0,466	0,830

5.2. Políticas de moderación

Se diseñó una política operativa basada en el vector de probabilidades de salida del modelo óptimo, que define tres estados según la probabilidad predictiva máxima $P = \max_k \hat{p}_k$:

- **Zona de Confianza** ($P \geq 0.85$): clasificación automática (alerta verde). Cubrió el 19,9 % de los registros de prueba (95 de 477), con una exactitud de 0,589 en dicha zona.
- **Zona de Incertidumbre** ($0.40 \leq P < 0.85$): clasificación asistida; el registro se deriva a una cola de auditoría humana (alerta amarilla).
- **Zona de Rechazo** ($P < 0.40$): descarte automático para mitigar el impacto del ruido ambiental (alerta roja).

La Figura 10 muestra la distribución de la confianza del modelo y la ubicación de los umbrales. Esta política permite derivar la incertidumbre a revisión experta y controlar los falsos positivos. Cabe señalar, sin embargo, una limitación crítica: la exactitud en la Zona de Confianza (0,589) es solo moderadamente superior a la *accuracy* global del modelo, lo que indica que una probabilidad máxima $P \geq 0,85$ **no garantiza** una alta tasa de acierto. Ello revela un modelo **insuficientemente calibrado**: las probabilidades de salida sobreestiman la confianza real. En un despliegue productivo sería recomendable, o bien elevar el umbral de automatización, o bien aplicar una calibración posterior (p. ej. *temperature scaling* o regresión isotónica) antes de confiar en la clasificación automática. Dada la criticidad ecológica de un falso positivo, la política conservadora actual –que envía el 75,7 % de los registros a auditoría– resulta prudente.




Figura 10: Distribución de la probabilidad máxima (confianza) del modelo y zonas operativas definidas por los umbrales 0.40 y 0.85.

Referencias

1. McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. arXiv:1802.03426.
2. van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
3. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD '16*.
4. Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.

Anexo A: *Contribution Statement*

Cuadro 7: Matriz de coevaluación del equipo de desarrollo.

Nombre del Integrante		% Contribución	Tareas encargadas
1.	NOMBRE 1	XX %	Tareas...
2.	NOMBRE 2	XX %	Tareas...
3.	NOMBRE 3	XX %	Tareas...
4.	NOMBRE 4	XX %	Tareas...

Repositorio del proyecto: <https://github.com/supermanzana-git/ml-ecoacoustic-species-classification>